

SUP'COM	Examen en Ingénierie des données	Année universitaire : 2025/2026
INDP2 A, B, C, D, E et F R. Abdelfattah, S. Ben Jebara, A. Benazza	Session Principale (le 18/12/2025) Durée : 1h30	Documents non autorisés
Barème Exercice 1 (6 pts) : 1, 0.5, 0.75, 1, 1.25, 1, 0.5 Exercice 2 (6 pts) : 1.5, 1, 1.5, 1, 1 Exercice 3 : (8 pts) : Partie I 0.5, 1.5, 1, 1 Partie II 1, 0.5, 0.5, 2		

Exercice 1 : Accidents de la route

Le jeu de données « Road_Accidents » contient les informations sur les 30773 accidents de la route recensés en Grande Bretagne pour la période 2021-2022. Plus précisément, pour chaque accident repéré par un identifiant unique ID, voici une partie des descripteurs :

- (Latitude, Longitude) : les deux coordonnées géographiques du lieu de l'accident,
- Number_of_Casualties : le nombre de victimes,
- Number_of_Vehicle : le nombre de véhicules impliqués,
- Speed_limit : La vitesse maximale autorisée par la loi sur le lieu de l'accident (l'unité de mesure est le *mile per hour* ou mph),
- Accident_Severity : la sévérité de l'accident (mortel, sérieux, léger)
- Road_Surface_Conditions : état de la surface de la route (sèche, humide, gelée, enneigée, inondée)
- Carriageway_Hazard : présence ou absence d'obstacles dangereux sur la route (par exemple, animaux, objets tombés sur la route)

1. Décrire précisément et brièvement une application qui peut utiliser ce jeu de données.

Plusieurs réponses sont possibles pour cette question. Par exemple, les autorités de gestion des routes peuvent analyser les types d'accidents et leur gravité selon le type d'infrastructure routière et les conditions externes (météo, présence d'obstacles) pour prendre des mesures correctives à titre préventif.

Un autre exemple c'est de développer une application SIG qui affiche les accidents sur une carte interactive (via les variables Latitude/Longitude) et identifie les zones à forte concentration d'accidents. Ou également, aider les autorités locales à prioriser des actions comme installation de radars, amélioration du revêtement, ajout de signalisation ... **1pt**

2. La variable « Speed_Limit » est-elle à ratio ou à intervalle ?

Il existe un zéro absolu qui signifie aucun mouvement. On peut faire des rapports pour comparer deux vitesses.

0.5 pt

3. Parmi les variables mentionnées, indiquer une variable :

a. Quantitative discrète,

Number_of_Casualties et Number_of_Vehicle 0.25 pt

b. Une variable qualitative ordinale,

Accident_Severity 0.25 pt

c. Une variable qualitative catégorielle.

Road_Surface_Conditions 0.25 pt

4. Le tableau 1 fournit le pourcentage de données manquantes pour les deux variables «Carriageway_Hazard» et «Accident_Severity». Quelle(s) solution(s) sont à adopter pour résoudre ce problème ?

Table 1 : Pourcentage de données manquantes pour certaines variables du dataset.

Variable	% données manquantes
Carriageway_Hazard	98.24
Accident_Severity	0.10

Il y a une écrasante majorité de données manquantes pour «Carriageway_Hazard» : on enlève cette variable.

0.5 pt

On peut imputer la variable binaire «Accident_Severity» par le mode (c.à.d la valeur la plus fréquente) ou d'utiliser d'autres variables.

0.5 pt

5. Le tableau 2 fournit quelques statistiques de la variable « Speed_limit ».

a. Tracer la boîte à moustache (*boxplot*) et conclure quant à la présence de valeurs aberrantes (*outliers*).


1,25pt (4 fois 0.25 pt+0.25 pt tracé)

On calcule l'intervalle interquartile $IQR=Q3-Q1=20$. **0.25pt**

On calcule la moustache basse $\max[\min, Q1-1.5IQR]=\max[10, 30-30]=10$ **0.25 pt**

On calcule la moustache haute $\min[\max, Q3+1.5IQR]=\min[80, 50+30]=80$ **0.25 pt**

Il n'y a pas d'outlier puisqu'il n'y a aucune valeur au-delà des moustaches. **0.25 pt**



b. Que peut-on dire sur la symétrie ou l'asymétrie de la distribution ?

Il s'agit d'une distribution asymétrique étalée à droite (queue à droite) puisque $\text{mode} < Q2 < \text{Moyenne}$. Le skewness ou coefficient d'asymétrie est positif. **1pt**

Table 2 : Statistiques de la variable « Speed limit » (en mph).

Min	Q1	Q2	Q3	Max	Moyenne	Mode
10	30	35	50	80	52	17

6. On veut créer une nouvelle variable permettant d'accéder au nombre d'accidents par gouvernorat. Comment s'appelle une telle création de variable ?

Il s'agit d'une opération d'agrégation de données qui permet de donner un aperçu à l'échelle locale de chaque gouvernorat sur les accidents qui y ont eu lieu. **0.5pt**

Exercice 2 : Scores des étudiants **5.5 pt**

On considère l'ensemble S de scores obtenu par un groupe de 28 étudiants :

50, 50, 49, 49, 49, 48, 48, 40, 39, 39, 35, 30, 30, 30, 30, 26, 25, 25, 24, 24, 23, 20, 20, 20, 19, 15, 14, 13, 10

1. Tracer l'histogramme à largeur égale à 8.

1.5 pt On voit que la dynamique est [10-50]

La largeur commune des bins est $50-10/N=8 \Rightarrow$ on aura 5 bins **0.25 pt**

En considérant l'histogramme de ce dataset on a :

[10 - 18[(10, 13, 14, 15) $\Rightarrow$ nbre d'occurrences 4 **0.25 pt**

[18 - 26[(19, 20, 20, 20, 23, 24, 24, 25, 25) $\Rightarrow$ nbre d'occurrences 9 **0.25 pt**

[26 - 34[(26, 30, 30, 30) $\Rightarrow$ nbre d'occurrences 4 **0.25 pt**

[34 - 42[(35, 39, 39, 40) $\Rightarrow$ nbre d'occurrences 4 **0.25 pt**

[42 - 50] (48, 48, 49, 49, 49, 50, 50) $\Rightarrow$ nbre d'occurrences 7 **0.25 pt**

2. Que peut-on dire sur la modalité de cet histogramme ?

1 pt L'histogramme présente deux pics de fréquence importants, l'un dans la classe [18 - 26[(fréquence 9) et l'autre dans la classe [42 - 50] (fréquence 7). Les autres classes ont une fréquence nettement plus faible (valeur 4). Il s'agit donc d'une distribution appelée bimodale.

3. Calculer la médiane de ces données. Expliquer si la moyenne arithmétique (valant environ 30.90) est un indicateur pertinent pour résumer cette distribution ou s'il vaut mieux utiliser la médiane.

1.5pt Le nombre de données est pair : la médiane est la demi-somme des valeurs de rang 14 (26) et 15 (30) $\Rightarrow (26+30)/2=28$ **0.5 pt**

Compte tenu de la forte dispersion des données la médiane constitue un indicateur plus fiable de la tendance centrale, car elle représente mieux le score « typique » d'un élève. **0.5 pt**

La moyenne tombe au milieu, là où il y a peu d'élèves. En effet, la moyenne ≈ 30.9 ne correspond à aucun groupe réel d'élèves. **0.25 pt**

Par contre, la médiane (28) est déjà plus proche du groupe majoritaire. **0.25 pt**

4. On applique maintenant une transformation logarithmique aux scores $S'' = \log_{10}(S)$. Expliquer comment cette transformation modifie la forme de l'histogramme.

1pt Une transformation logarithmique agit principalement en compressant les grandes valeurs et en étirant les petites valeurs. Dans le cas de cet histogramme bimodal :

- Les valeurs de la classe haute [42-50] sont fortement compressées, **0.25 pt**
- Les petites valeurs de [10-18] sont légèrement étirées, rendant la classe plus visible. **0.25 pt**

- L'écart entre classes se réduit : les deux groupes initialement distincts deviennent plus proches. **0.25 pt**
- La bimodalité s'atténue considérablement et la distribution apparaît plus compacte et presque unimodale, dominée par la classe [18–26]. **0.25 pt**

5. Le club des étudiants étudie les offres de deux librairies X et Y d'un même produit sous différents formats. La table 3 fournit les statistiques des prix des différentes versions.

Table 3 : Quelques statistiques des prix du même produit (sous différents formats) selon le magasin.

Magasin	Prix moyen (en TND)	Écart-type (en TND)
X	10	3
Y	25	4

- Quel magasin présente la plus grande dispersion absolue ?
- Quel magasin présente la plus grande dispersion relative qui est définie comme le rapport écart-type sur moyenne ?
- Expliquer l'intérêt de la dispersion absolue et de la dispersion relative pour faciliter le choix du club des étudiants pour des prix stables.

1 pt (0.25, 0.25, 0.5)

- Dispersion absolue (écart-type) Le Magasin Y présente la plus grande dispersion absolue valant 4. (0.25 pt)**
- Dispersion relative (coefficient de variation) $CV(X) = 3 / 10 = 0,30$ (30 %) $CV(Y) = 4 / 25 = 0,16$ (16 %) Le magasin X a la plus grande dispersion relative. 0.25 pt**
- Si le club veut éviter des prix trop variables en valeur absolue, il choisira le magasin X. Si un client veut éviter des prix variables proportionnellement au prix moyen, il choisira le magasin Y. 0.5 pt**

Exercice 3 : Analyse en composantes principales

Un opérateur mobile souhaite analyser les données relatives à ses clients en se basant sur les six variables suivantes :

- Data_Usage (Mo/mois) : volume total de données mobiles consommées par le client chaque mois.
- Voice_Minutes (min/mois) : nombre total de minutes d'appel consommées par le client chaque mois.
- Montant_Facture (TND) : montant mensuel payé par le client, incluant l'abonnement et les éventuelles options.
- Ancienneté (mois) : durée depuis laquelle le client est abonné à l'opérateur.
- Satisfaction (/10) : score global de satisfaction fourni par le client.
- Incidents (par mois) : nombre d'incidents techniques ou réclamations déclarés par le client.

Pour illustrer l'application de l'ACP sur un jeu de données télécoms réaliste, on s'intéresse à un échantillon composé de 8 clients ayant un abonnement de type postpayé. Les données caractéristiques sont fournies dans la table 4.

Table 4 : Données caractéristiques de 8 clients ayant un abonnement de type postpayé.

Client	Data_Usage (Mo)	Voice_Minutes (min/mois)	Montant_Facture (TND)	Ancienneté_Contrat (mois)	Satisfaction (/10)	Incidents
C1	2400	190	32	18	7.1	1
C2	3100	220	37	24	8.3	0
C3	600	80	18	6	4.0	3
C4	750	110	21	9	5.2	2
C5	2100	160	29	14	7.0	1
C6	1650	140	27	12	6.1	1
C7	450	60	15	4	3.8	4
C8	2900	210	35	22	8.1	0

PARTIE I – Compréhension approfondie de l'ACP (contexte Télécom)

I.1 Dans quelle étape et quelle phase du processus CRISP-DM se situe l'Analyse en Composantes Principales (ACP) ?

0.5 pt L'Analyse en Composantes Principales (ACP) appartient à la phase 3 du CRISP-DM : Data Preparation. Plus précisément, elle se situe dans la sous-étape : Transformation des données (Data Construction ou Formatage des données).

I.2 Pourquoi l'ACP est-elle pertinente dans l'analyse de clients ayant un abonnement de type postpayé_?

1.5 pt L'ACP est pertinente car :

- Les variables `Data_Usage`, `Voice_Minutes` et `Montant_Facture` sont corrélées : dans un contrat postpayé, un client qui consomme beaucoup paie généralement plus
- Les services postpayés créent une structure temporelle (ancienneté, facture stable, habitudes d'usage).
- Les variables `Satisfaction` et `Incidents` traduisent une autre dimension : l'expérience client.
- L'ACP réduit la dimension tout en conservant structure et variances importantes, facilitant :
 - la segmentation/classification,
 - la détection du churn,
 - la visualisation de groupes de clients,
 - la préparation de données pour du machine learning.

I.3 En tenant compte de la diversité des variables utilisées par les opérateurs télécoms, expliquez pourquoi centrer simplement les variables ne suffit pas dans ce cas, et pourquoi l'on préfère généralement une standardisation complète avant l'ACP.

1 pt

- Les échelles sont très différentes : Mo, minutes, TND, mois, score sur 10, incidents.
- Sans réduction, les variables à forte variance (`Data_Usage`, `Voice_Minutes`) domineraient artificiellement les premières composantes.
- La standardisation met toutes les variables sur le même pied (variance = 1), rendant l'ACP sensible aux corrélations plutôt qu'aux unités.

I.4 Pourquoi l'ACP améliore-t-elle l'analyse statistique tout en rendant plus difficile l'interprétation métier (Télécom)?

1 pt

- L'ACP donne des combinaisons linéaires des variables (PCs), optimales statistiquement.
- Mais ces nouvelles variables générées par l'ACP ne sont pas des variables métiers naturelles.
- Les équipes marketing préfèrent des indicateurs clairs ("Montant", "Satisfaction") plutôt qu'un axe abstrait/artificiel.

PARTIE II – Calculs numériques de l'Analyse en Composantes Principales

On considère la matrice de covariance (standardisée) pour les trois variables [`Data_Usage`, `Voice_Minutes`, `Montant_Facture`] :

$$\Sigma = \begin{pmatrix} 1.00 & 0.90 & 0.85 \\ 0.90 & 1.00 & 0.80 \\ 0.85 & 0.80 & 1.00 \end{pmatrix}$$

Deux valeurs propres correspondantes à la matrice de covariance Σ sont : **0.21** et **0.09**.

II.1 À partir du tableau 4, écrire les formules matricielles (sans effectuer les calculs) qui permettent de construire la matrice de covariance Σ .

1 pt

- Calcul du vecteur des moyennes : $\bar{\mu} = (1743.75, 146.25, 26.75)$
- Centrer la matrice des échantillons (dataframe initial) :

$$\tilde{X} = X - \bar{\mu} = \begin{pmatrix} 656.25 & 43.75 & 5.25 \\ 1356.25 & 73.75 & 10.25 \\ -1143.75 & -66.25 & -8.75 \\ -993.75 & -36.25 & -5.75 \\ 356.25 & 13.75 & 2.25 \\ -93.75 & -6.25 & 0.25 \\ -1293.75 & -86.25 & -11.75 \\ 1156.25 & 63.75 & 8.25 \end{pmatrix}$$

- Calcul de la matrice de covariance

$$S = \frac{1}{7} \tilde{X}^T \tilde{X} \quad (3 \times 3)$$

- Calcul des variances

$$\begin{aligned}\sigma &= (\sigma_1, \sigma_2, \sigma_3) \\ \sigma_1^2 &= S(1, 1) \\ \sigma_2^2 &= S(2, 2) \\ \sigma_3^2 &= S(3, 3)\end{aligned}$$

- Mise à l'échelle

$$\begin{aligned}\Sigma(i, j) &= \frac{S(i, j)}{\sigma_i \sigma_j} \\ i, j &\in \{1, 2, 3\}\end{aligned}$$

II.2 Interprétez les valeurs de la matrice de corrélation.

0.5 pt

Les corrélations sont très élevées (≈ 0.99), ceci indique que les trois variables partagent un axe dominant en ACP.

II.3 À partir des valeurs propres déjà obtenues, en déduire la troisième valeur propre.

0.5 pt

La somme des valeurs propres = $\text{trace}(\Sigma) = 3$, d'où $\lambda = 3 - (2.21 + 0.09) = 2.7$

II.4 Calculer la proportion de variance expliquée par chaque composante (en %). En déduire le nombre de dimensions à retenir pour effectuer la réduction dimensionnelle.

2 pt

Variance expliquée : **0.25 pt (formule)**

- PC1 : $\frac{2.7}{3} = 0.90 \rightarrow 90\%$ (arrondi 90.0 %) **0.25 pt**
- PC2 : $\frac{0.21}{3.0} = 0.069 \rightarrow 6.91\%$ ($\approx 6.9\%$) **0.25 pt**
- PC3 : $\frac{0.09}{3} = 0.0306 \rightarrow 3.06\%$ ($\approx 3.1\%$) **0.25 pt**

Variance cumulée : **0.5 pt**

- Après PC1 : 90.02 %
- Après PC1+PC2 : $90.02 + 6.91 = 96.93\%$

Ici PC1 capture $\sim 90\%$ de la variance — on peut raisonnablement réduire à 1 dimension pour ces 3 variables.

0.5 pt